



თბილისის თავისუფალი უნივერსიტეტი

კომპიუტერული მეცნიერებების, მათემატიკისა და ინჟინერიის
სკოლა (MACS[E])

ელექტრო და კომპიუტერული ინჟინერიის პროგრამა

ლუკა ნადირაძე

ჯუნიორ პროექტი

Ground Penetrating Radar

ხელმძღვანელი: ვახტანგ ჯანდიერი

თბილისი

2020

ანოტაცია

პროექტი არის GPR-ის (Ground Penetrating Radar) მონაცემების მანქანური სწავლების გამოყენებით დამუშავების მეთოდის და ამით მიწაში დამარხული ობიექტების აღმოჩენის შესახებ. მონაცემების შეგროვებისთვის გამოყენებულია ორი ვივალდის ანტენა ბისტატიკურ რეჟიმში, Rohdze-Schwarz ფირმის ვექტორულ ქსელურ ანალიზატორთან (VNA) ერთად. არსებობს GPR-ის სიგნალების დამუშავების სხვადასხვა მეთოდი, თუმცა წარმოდგენილი მეთოდი ამ სფეროში ჯერ არ ყოფილა გამოყენებული. VNA-ით S-პარამეტრების შეგროვების შემდეგ გამოყენებულია ლოგისტიკური რეგრესიის მოდელი მათი კლასიფიცირებისთვის. მიღებულ მოდელს გავლილი არის cross-validated და შედეგად 80% სიზუსტით შეუძლია მიწაში 7-10სმ-ზე დამარხული LiPo ბატარიების აღმოჩენა. ბუნებრივია, კლასიფიკაციის ბარიერის ცვლილება შეიძლება რათა შევამციროთ ცრუ დადებითი ან ცრუ უარყოფითი მონაცემების რაოდენობა. ამჟამინდელი სიზუსტის მნიშვნელოვნად გაუმჯობესებაა შესაძლებელი, რადგან შეგროვილი მონაცემები ამჟამად შეუთავსებელია, VNA-ს არ აქვს კალიბრაცია გავლილი, და სიგნალები არაა გაფილტრული. შეგროვილი მონაცემები მარკირებული და თავისუფლად ხელმისაწვდომია. აგრეთვე ხელმისაწვდომია ყველა დაწერილი კოდი jupyter notebook ფორმატში, რაც პროექტის გამეორებას უფრო ხელმისაწვდომს ხდის. პროექტის შექმნისას ბევრი გამოსადეგი სკრიპტი დაიწერა, ძირითადად Python-ში. ბიბლიოთეკები, როგორებიცაა Pandas, Numpy და Matplotlib გამოყენებული იყო მონაცემების დამუშავებისთვის და ვიზუალიზაციისთვის, Sklearn ბიბლიოთეკა მოდელის მორგებისთვის, PyAutoGUI მონაცემთა შეგროვების ავტომატიზაციისთვის და ა.შ. ეს მეთოდი დამაიმედებელ შედეგს იძლევა უფრო ფართო გამოყენებისთვის და მიზნად ისახავს უფრო მეტი კვლევის წარმოებას ამ მიმართულებით.

This project is about using machine learning for processing GPR (Ground Penetrating Radar) data and predicting the locations of buried objects. Two Vivaldi Antennas are used in bistatic mode, along with Rohde-Schwarz VNA (Vector Network Analyzer) are used for capturing data. There are various methods for processing GPR data, but proposed method has not been used before in this field. After acquiring S-parameters from VNA, Logistic Regression model is used for classifying GPR data. This model is cross-validated and has 80% locating accuracy for buried LiPo batteries in sand at 7-10cm depth. Naturally, threshold can be varied to reduce either false positive or true negative ratio. Current score can be drastically improved because collected data was not consistent, VNA was not calibrated, and signals were not filtered. Collected data is available and labeled, code is also available in form of jupyter notebooks, which makes this project easier to reproduce. During the making of this project, many small useful scripts were developed, mainly in Python. Libraries, like Pandas, Numpy and Matplotlib are used for manipulating and visualizing data, Sklearn library is used for fitting, PyAutoGUI for automating data collection on VNA, etc. This method shows promise for wider applications and aims to direct more research to this subject.

სარჩევი

შესავალი	4
ამოცანის დასმა	6
ტექნიკური მხარე	12
გამოყენებული მასალები და მათი აღწერა	13
საექსპერიმენტო გარემოს მოწყობა	14
VNA-ს კალიბრაცია	15
მონაცემების შეგროვება.....	16
data-miner-v1	16
data-miner-v2	17
servo-controller.....	17
მონაცემების დამუშავება და მოდელის შექმნა.....	18
მიღებული შედეგი და დასკვნა	22

შესავალი

არსებული პროექტის იდეა წარმოიშვა ლექტორთან გასაუბრების დროს, როცა განვიხილავდით სხვადასხვა შესაძლო განსახორციელებელ პროექტებს. ზოგადად ეს ტექნოლოგია არსებობს და მეტნაკლები წარმატებით გამოიყენება, ძირითადად, არქეოლოგიის და სამხედრო დარგებში. ინჟინერიაში მისი გამოყენების არეალი მოიცავს ქვაფენილებისა და სხვადასხვა სტრუქტურების არადესტრუქციულ ტესტირებას და მიწისქვეშ არსებული სტრუქტურების, მაგალითად გაყვანილობის მილების, ლოკალიზებას. არქეოლოგიაში მას იყენებენ სამარხების აღმოსაჩენად და სხვადასხვა არქეოლოგიური მახასიათებლების რუკის შესადგენად, ხოლო სამართალდამცავებისთვის GPR გამოსადეგია ფარული საფლავების ან მტკიცებულებების აღმოსაჩენად. სამხედრო მიზნით მისი გამოყენება შესაძლებელია ნაღმების, აუფეთქებული ჭურვების ან ტუნელების მოსაძებნად.

მიუხედავად იმისა, რომ ზოგიერთ საქმეში ეს ტექნოლოგია შეიძლება უალტერნატივო იყოს, როგორც ყველა ტექნოლოგიას, ისე GPR-საც გააჩნია გარკვეული შეზღუდვები, რაც მას ზოგიერთ შემთხვევაში არაპრაქტიკულს ხდის. სხვა შეზღუდვებზე მოგვიანებით ვისაუბრებ, მაგრამ ჩემს კონკრეტულ შემთხვევაში გამოწვევა იყო GPR-ისგან მიღებული სიგნალის დამუშავების ნაწილი, რაზეც წარსულში ნამუშევარი ჰქონდა პროექტის ხელმძღვანელს და მისგან ვიცოდი, რომ სიგნალების დამუშავების საკითხში იყო ზოგიერთი რამ, რისი უკეთ გაკეთებაც შეიძლებოდა. ამასთან, შესაძლებელი იყო ყველა საჭირო ექსპერიმენტის ჩატარება და არა მისი სიმულაცია, რადგან უნივერსიტეტში იყო ამისთვის საჭირო მთავარი ხელსაწყო (VNA), ხოლო ანტენების და სხვა მასალების შეძენა პროექტის ფარგლებში იყო შესაძლებელი. საბოლოოდ იდეა ისე ჩამოყალიბდა, რომ სრულიად შეიცვალა პრობლემის მიმართ მიდგომა და სიგნალის მიღების შემდეგ მისი დამუშავება გადაწყვიტე აქამდე არ ნაცადი მეთოდით.

ზოგიერთმა შეიძლება იფიქროს, რომ ეს ტექნოლოგია ბოლომდეა დახვეწილი და ვერც ერთი სიახლე მას მნიშვნელოვნად ვეღარ გააუმჯობესებს. თუმცა ერთ-ერთი ვრცელი ნაშრომის მიხედვით ისეთი კარგად შესწავლილი დარგი, როგორიც მიწისქვეშ ნაღმების აღმოჩენაა, ჯერ კიდევ პრობლემურია. თუ ზუსტად რაშია პრობლემა, განვიხილოთ ეს კონკრეტული შემთხვევა უფრო დეტალურად. დღესდღეისობით, განადმვა სრულდება ერთმანეთისგან განსხვავებული განადმვის სისტემებით, როგორებიცაა მექანიკური ექსკავაცია, გაწვრთნილი ძალების ან მეტალოდეტექტორების გამოყენება. ამ დარგში ყველაზე ხშირად გამოყენებულ ტექნოლოგიად რჩება მეტალოდეტექტორი, მაგრამ თანამედროვე ცოცხალი ძალების განმანადგურებელი ნაღმები აღარ მზადდება მეტალის მნიშვნელოვანი წილის შემცველობით. ამჟამად ნაღმებში პლასტმასის და სხვა არამეტალური ნივთიერებების წილი ბევრად უფრო მეტია. ისეთ ადგილას, სადაც მიწა დაბინძურებულია მეტალის ნარჩენებით, მეტალოდეტექტორებს არ შეუძლიათ ეფექტურად აღმოაჩინონ ნაღმები მათში მეტალის მწირი შემცველობის გამო. ამის საკომპენსაციოდ, ზოგიერთი სენსორი ოპერატორს აძლევს საშუალებას გაზარდოს მგრძნობელობა, თუმცა ამას ბუნებრივად მოჰყვება გაზრდილი ცრუ განგაშების რაოდენობა. ყოველ აღმოჩენილ ნაღმზე მოდის 500-ზე მეტი აღმოჩენილი უსაფრთხო ნივთი, მაგალითად ხელყუმბარის ფრაგმენტები და ვაზნები. ცრუ განგაშის სიხშირე, ისევე როგორც დაბალი მეტალის შიგთავსის მქონე ნაღმების ვერ აღმოჩენა, ართულებს განადმვის ოპერაციებს, ხდის მათ უფრო საშიშს, ძვირს და დიდ დროსთან დაკავშირებულს.

სწორედ ასეთ შემთხვევაში შეიძლება GPR-ის გამოყენება, რომელსაც თანაბარი წარმატებით შეუძლია მეტალური და არამეტალური ნაღმების აღმოჩენა. თუმცა, გაუმჯობესებისთვის სივრცე აქაც არის, რადგან მცირე ზომის ნაღმებისთვის, GPR პრაქტიკაში გამოიყენება მეტალოდეტექტორებთან ერთად.

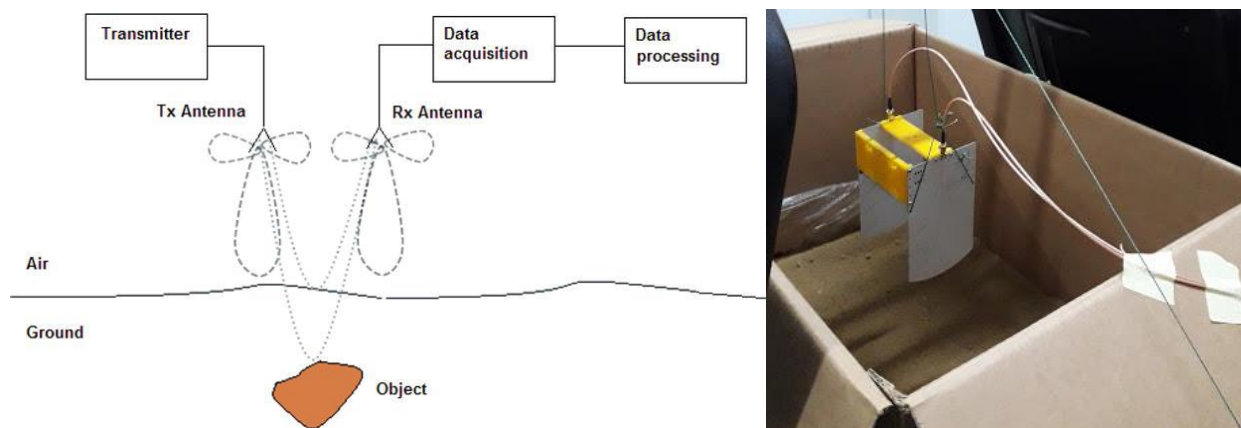
ახლა უკვე გასაგები უნდა იყოს, რომ GPR-ის იმპლემენტაცია უამრავ სფეროში შეიძლება, თუმცა პროექტისთვის აუცილებელი იყო ერთ რომელიმე კონკრეტულ სფეროზე კონცენტრირება. გადაწყვიტე, რომ არჩეული სფერო კავშირში ყოფილიყო ქვიშაში ნაღმის მსგავსი ობიექტების აღმოჩენასთან. მოცემული სფერო იმიტომ ავირჩიე, რომ მარტივად შეიძლება სხვა სფეროებზე განზოგადება. თუ გამოვიდოდა მიწაში დამარხული, საშუალოზე მცირე ზომის, არაჰომოგენური ობიექტის აღმოჩენა, დარწმუნებით შევძლებდით გვეთქვა, რომ იგივე პრინციპი იმუშავებდა სხვა მსგავს ან უფრო მარტივ შემთხვევებშიც. შესაბამისად, დავისახე კონკრეტული მიზანი, რომ GPR-ისგან მიღებული სიგნალის დამუშავებით, რაც შეიძლება მაღალი სიზუსტით უნდა გამერჩია, იყო თუ არა ქვიშაში რაიმე კონკრეტული ნივთი დამარხული. ამ მიზნის შესასრულებლად ვიფიქრე, რომ საინტერესო იქნებოდა ხელოვნური ინტელექტის გამოყენება და მისი პოტენციალის შეფასება მომავალი კვლევებისთვის. სხვა "უსაფრთხო" გადაჭრის გზებთან შედარებით, ეს მეთოდი იყო უფრო სარისკო და რთული, რადგან არ არსებობდა დამხმარე მასალა, რაზე დაყრდნობასაც შევძლებდით, შედეგი კი სრულიად ბუნდოვანი იყო, შეიძლებოდა ჩემს მიერ მიღებულ მოდელს საერთოდ არ ემუშავა.

საბოლოოდ გადაწყვიტე, რომ ღირდა ცდად ახალი მეთოდის გამოყენება. პროექტის კეთებისას შევისწავლიდი მანქანური სწავლების საფუძვლებს, მონაცემების დამუშავებას, ექსპერიმენტის სწორად ჩატარებას, განვივითარებდი პრობლემების გადაჭრის უნარებს და ჯამში ეს პროცესი იქნებოდა უფრო საინტერესო, ვიდრე არსებული მეთოდების და ალგორითმების გამოყენება. რაღაც მხრივ გამიმართლა, რომ ეს მიდგომა ავარჩიე, რადგან ვფიქრობ, რომ VNA-ის კალიბრაციის პრობლემის გადაჭრას ავარიდე თავი, რაც დიდ თანხასთან იყო დაკავშირებული. მიღებული შედეგებიც საინტერესოა და ჩემი აზრით, აჩენს კვლევის ამ მიმართულებით გაგრძელების მოტივაციას.

ამოცანის დასმა

პროექტისთვის საჭირო ექსპერიმენტების ჩატარებამდე, ჯერ ვეცნობოდი არსებულ თემაზე შესრულებულ ნაშრომებს და GPR-ის დახმარებით გამოსახულების მიღების სხვადასხვა ალგორითმებს. როცა საკმარისად დავრწმუნდი, რომ მესმოდა ამ პრობლემისადმი არსებული მიდგომები (უმეტესად მხოლოდ პრინციპი, ზედმეტი კონკრეტიკის გარეშე), ჩავთვალე რომ მზად ვიყავი საკუთარი ექსპერიმენტის განსახორციელებლად. თუმცა, სანამ ჩემი პროექტის ტექნიკურ მხარეზე შევძლებ ლაპარაკს, სხვებისთვისაც საჭიროა GPR-ის მუშაობის პრინციპის გაცნობა, რათა გამოიკვეთოს ჩემს მიერ შემოთავაზებული გადაჭრის გზის თავისებურებები და შევძლო უფრო დეტალებში ვისაუბრო ჩემი პროექტის შესახებ. GPR-ის არსებული მეთოდოლოგიის აღწერისას ნაკლებად შევეხები ფორმულებს და მის რთულ მათემატიკურ მხარეს. ამ ეტაპზე ინტუიციის გამომუშავება სრულიად საკმარისი იქნება.


მასალების ელექტრული მახასიათებლები მათ გამტარობაზე, დიელექტრიკულ შეღწევადობასა და მაგნიტურ შეღწევადობაზეა დამოკიდებული, რომლებიც სიხშირის ფუნქციებია. მედიუმის ფარდობითი დიელექტრიკული შეღწევადობა (ან ელექტრული მუდმივა) გავლენას ახდენს ელექტრული ველის გავრცელებაზე და GPR-ისთვის ყველაზე მნიშვნელოვანი და საჭირო პარამეტრია. ფარდობითი მაგნიტურ შეღწევადობას მაგნიტური ველის გავრცელებაზე აქვს გავლენა. მიწისქვეშ ელექტრომაგნიტური ტალღის შესუსტება ძლიერად არის დამოკიდებული მედიუმის ელექტრულ გამტარობაზე, ამ მახასიათებელს კი უმეტესად წყალი (ტენიანობა) განაპირობებს. გამტარების შემთხვევაში ელექტრული ველი შთაინთქმება და ხელს უშლის მის გავრცელებას. თუ ნივთიერება რეზისტული ან დიელექტრიკულია, მაშინ ელექტრომაგნიტურ ველს მასში გავრცელება შეუძლია. როცა ელექტრომაგნიტურ ტალღას ვგზავნით მიწაში, GPR ზომავს გარემოს შეცვლის ადგილიდან არეკლილ ექოებს. ქვემოთ მოცემული მარცხენა სურათი აღნიშნავს ტიპური GPR სისტემის მუშაობის ბლოკ-სქემას, ხოლო მარჯვენა მხარეს უნივერსიტეტის ლაბორატორიაში აწყობილი GPR არის.



სურათი 1. GPR სისტემის ბლოკ-სქემა და ჩვენი ვერსია


GPR მიწაში გზავნის მიკროტალღური სპექტრის სიგნალებს (ჩვენს შემთხვევაში სიხშირით 1.7გჰც-დან 8.5გჰც-მდე) და აკვირდება ანომალიებს არეკლილ სიგნალში, რომელიც შეიძლება დამარხული ნივთის არსებობას აღნიშნავდეს. დამარხული ობიექტის ამოცნობის მაგალითზე, რადარის მიერ დაფიქსირებული ექოების სიძლიერე დამოკიდებულია ელექტრომაგნიტური მახასიათებლების კონტრასტზე სამიზნე ობიექტსა და მის გარშემო მყოფ ნიადაგს შორის.

როცა GPR გაგზავნის ტალღას გადამცემი ანტენიდან, რომელიც მიწის ზევით მდებარეობს, სიგნალი გადაადგილდება ჰაერში და როცა ელექტრომაგნიტური ტალღა მიაღწევს ნებისმიერ ელექტრულ წყვეტას, ხდება არეკვა. არეკლილი ტალღა მიმდები ანტენის მიერ იზომება. პირველად ის გაზომავს ჰაერისა და მიწის საზღვრიდან არეკლილ ტალღას, ხოლო ოდნავ მოგვიანებით მიწაში არსებული განსხვავებული მახასიათებლის ობიექტისგან არეკლილ ტალღას. რასაკვირველია, გაგზავნილი ტალღის რაღაც ნაწილი უბრალოდ გარდატყდება და მის გავრცელებასთან ერთად ნელ-ნელა შთაინთქმება. როცა GPR-ით ასეთ გაზომვას ვატარებთ, მას A-scan ეწოდება. A-scan ნიშნავს ერთი კონკრეტული (x, y) ადგილიდან გაზომილ სიგნალს. ასეთ მონაცემში ერთადერთი ცვლადი არის დრო t , რომელიც მედიუმში ტალღის გავრცელების სიჩქარიდან დაკავშირებული სიღრმე z -თან. A-scan გამოსახულია ქვედა სურათზე.




სურათი 2. A-scan

თუ GPR ანტენებს x ღერძის გასწვრივ ავამოძრავებთ და შევაგროვებთ A-scan-ების სიმრავლეს, შეიკვრება ორგანოზომილებიანი მატრიცა, რომელსაც B-scan ეწოდება. როცა მიღებული სიგნალის ამპლიტუდას ფერებს შევუსაბამებთ, მივიღებთ ისეთ 2D სურათს, რაც მომდევნო გვერდზეა მოცემული. ეს სურათი აღნიშნავს ნიადაგის ვერტიკალურ ჭრილს. ასეთ სურათზე მიწის ქვეშ განთავსებული ობიექტი ჩანს ისე, თითქოს ჰიპერბოლური ფორმა აქვს. თუ რატომ ხდება ასე, შეგვიძლია ამის [საილუსტრაციო ანიმაცია ვნახოთ](#).




სურათი 3. B-scan სურათის მიღება

საბოლოოდ, როცა ანტენას xy სიბრტყეში ბადეზე ვამოძრავებთ, მივიღებთ 3D მონაცემთა სიმრავლეს, რომელსაც C-scan ეწოდება. როგორც წესი, C-scan წარმოდგენილია როგორც 2D სურათი, რომელიც დროზე/სიღრმეზე არის დამოკიდებული, ეს კი ნიადაგში ჰორიზონტალურ ქრილს აღნიშნავს. არსებობენ თანამედროვე სამომხმარებლო პროგრამები (მაგ. GPRMax2D და 3D), რომლებსაც გააჩნიათ ჩაშენებული ფუნქციონალი C-scan სურათების დასახატად. ამის მაგალითები ქვემოთაა მოცემული.




სურათი 4. C-scan სურათის მიღება

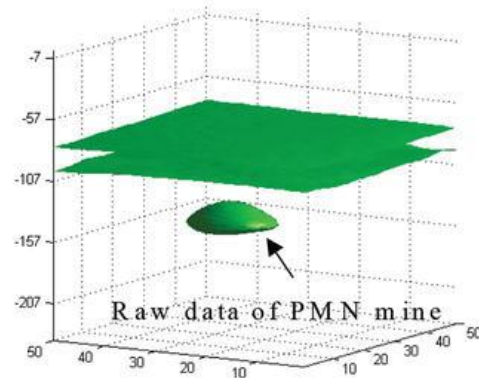


სურათი 5. GprMax პროგრამით მიღებული C-scan სურათი


ცხადია, რომ ამ თემაზე უამრავი დეტალია, რაც არ მიხსენებია და ზემოთ მოყვანილი გამოსახულებების მიღება არც ისე მარტივია. მაგალითად, არ მიხსენებია თუ როგორ იფილტრება GPR-ისგან მიღებული სიგნალი, რისთვისაც ბევრი ისეთი ჭკვიანური მეთოდია შემუშავებული, რომლებიც კარგად ართმევენ დავალებას თავს. გაფილტრული სიგნალის მაგალითი, თუ რამდენად ასუფთავებს იგი გამოსახულებას, მოცემულია ქვედა სურათზე. GPR-ის მთავარი ფუნქციაა აღმოაჩინოს ელექტრომაგნიტური მახასიათებლების განსხვავება ნიადაგსა და სამიზნე ობიექტს შორის. ეს საშუალებას გვაძლევს არამეტალური ობიექტებიც კი ამოვიცნოთ. თუმცა, გარდა იმისა, რომ ჩვენ პასუხს ვიღებთ პოტენციური სამიზნისგან, არეკლილი სიგნალი შეიცავს ისეთ არასასურველ ეფექტებს, რომლებიც ნაწილობრივ ან სრულად გადაფარავენ სამიზნის პასუხს. ამიტომ, რომ ჯერ კიდევ სიგნალის მიღებამდე ხდება GPR-ის კალიბრაცია და დამახინჯებული სიგნალის გაფილტვრა. გაფილტვრის შემდეგ (საჭირო პარამეტრების ცოდნის შემთხვევაში) შესაძლებელია GPR-ის ერთ სიბრტყეში ფოკუსირებაც, რაც ანტენის რეზოლუციას ზრდის ეფექტურად. ეს მეთოდებიც მრავალნაირი არსებობს და ძალიან საინტერესოა, თუმცა ამ თემაზე დეტალურად აღარ ვისაუბრებ, რადგან გამოჩნდება, რომ მიუხედავად უამრავი ლიმიტაციისა, ჩემს მიერ შემოთავაზებული მოდელი მაინც შეძლებს საინტერესო შედეგი მოგვცეს, მათ შორის სიგნალების გაფილტვრის გარეშეც კი.



სურათი 6. გაუფილტრავი (მარცხნივ) და გაფილტრული (მარჯვნივ) B-scan სურათი



სურათი 7. C-scan სურათით აღმოჩენილი ნაღმი



სურათი 8. H ფორმის ობიექტი ფოკუსირებამდე და ფოკუსირების შემდეგ

ზემოხსენებული ინფორმაციის გათვალისწინებით, ვცდი ვისაუბრო საკუთარ მეთოდზე, რაც გულისხმობს ხელოვნური ინტელექტის დახმარებით არსებული პრობლემის გადაჭრას. იდეა შემთხვევითი იყო, ამ დროს ხელოვნური ინტელექტის ტრენინგებს ვესწრებოდი და ხშირად ვფიქრობდი მის პრაქტიკაში გამოყენებაზე. ზოგადად, როცა ხელოვნურ ინტელექტზე საუბრობენ, არსებობს გამართლებული სკეპტიციზმი, რადგან ის ხშირად გვხვდება როგორც მოდური სიტყვა და მიუხედავად იმისა, რომ აქვს გამოყენების სპეციფიკური არეალი, მას დაუნდობლად იყენებენ თითქმის ყველა თანამედროვე პროექტსა თუ სტარტაპში. რეალურად ძალიან რთულია შექმნა მიუკერძოებელი მოდელი. პრობლემის დასმა, კარგი მონაცემების შეგროვება, სწორი მოდელის შერჩევა, მის მიუკერძოებლობაში დარწმუნება, შედეგების ინტერპრეტაცია, ეს ყველაფერი საჭიროა მოხდეს ძალიან გათვლილად და ფრთხილად, რათა არ გავაკეთოთ მცდარი დასკვნები. პროექტის მსვლელობისას შეგვხვდება რამდენიმე მომენტი, სადაც ერთი შეხედვით, ყველაფერი იდეალურადაა. თუმცა საჭიროა თვითკრიტიკა, საკუთარი მოდელის მკაცრი გატესტვა და ასე, ნაბიჯ-ნაბიჯ, ლოგიკური დასკვნისკენ მოძრაობა.

რადგან ვთქვი, რომ ხელოვნურ ინტელექტთან საჭიროა დიდი სიფრთხილე, დავასახელებ მოტივაციასაც, თუ რატომ ავირჩიე მაინცდამაინც ეს მიდგომა:

- მანქანური სწავლება სწრაფად მზარდი და განვითარებადი სამეცნიერო სფეროა, რომელიც აერთიანებს ჩემთვის ყველაზე საინტერესო რამდენიმე დარგს. ეს სფერო სულაც არაა ახალი და საფუძველს გასულ საუკუნეში იღებს, თუმცა მისთვის მეორე სიცოცხლის მინიჭება მონაცემების რაოდენობის აფეთქებამ გამოიწვია. ამჟამად, როცა ერთ წელიწადში უფრო მეტი ინფორმაცია იქმნება, ვიდრე მანამდე მთლიანად კაცობრიობის ისტორიაში, მათ დამუშავებასა და ინტერპრეტაციაზე მოთხოვნა მუდმივად იზრდება. ვხვდებით მანქანური სწავლების სხვადასხვა სფეროებში გამოყენების წარმატებულ თუ წარუმატებელ მაგალითებსაც. შესაბამისად, ახლა, როცა დიდი რაოდენობით მონაცემების შეგროვება ძალიან გამარტივებულია, ამ სფეროში AI-ს შესაძლებლობების მოსინჯვის სურვილი, ვფიქრობ, რომ ბუნებრივი ინტერესითაც იყო განპირობებული.
- როგორც ვიცი, GPR-თან ერთად მანქანური სწავლების გამოყენება ჯერ არავის უცდია, ამიტომ კარგი იქნებოდა თუ ერთ-ერთი პირველი დავსვამდი ამ საკითხს, რაც წარმატების შემთხვევაში, სხვებს ამ მიმართულებით დამატებითი კვლევის მოტივაციას გაუჩენდა, ხოლო წარუმატებლობის შემთხვევაში სხვები აღარ დაკარგავდნენ დროს და ეცდებოდნენ პრობლემის რეფორმულირებას.

- ხელოვნური ინტელექტის გაწვრთნა მოითხოვს ბევრად ნაკლებ დროს და ადამიანურ რესურსს. მას მოხმარებისას არ სჭირდება სიგნალების ზედმიწევნით დამუშავება და მათემატიკური აპარატის მორგება. აგრეთვე არ დაგჭირდება არც ერთი მახასიათებლების, მაგალითად ნივთიერებების დიელექტრიკული შედგენადობების, წინასწარ ცოდნა. ერთხელ წარმატებული დატრენინგების შემთხვევაში მომხმარებელი შეძლებს შეინარჩუნოს და მუდმივად გააუმჯობესოს მოდელი. ამასთან, GPR-ის ერთ-ერთი დიდი მინუსი ისაა, რომ ადამიანებს არ შეუძლიათ წაიკითხონ რადიოგრამა, თუ ისინი წინასწარ კარგად ნავარჯიშები არ არიან. ხელოვნური ინტელექტის დახმარება ამ პრობლემის აღმოფხვრაშიც შეგვიწყობდა ხელს.
- სისტემურ შეცდომებს, რაც გაზომვისას ხდება, არ ექნებათ ისეთი ცუდი გავლენა შედეგზე, როგორც მას სიგნალის სტანდარტული დამუშავების შემთხვევაში ექნებოდა. ყველაფერთან ერთად, ასეთი მოდელი არ გაახანგრძლივებს მონაცემების დამუშავებისთვის საჭირო დროს. დროის დახარჯვა მხოლოდ ტრენინგის პროცესში იქნება საჭირო. მომხმარებლის მიერ მისი დატრენინგების შესაძლებლობის არსებობა კი ხელს შეუწყობს GPR-ის მორგებას კონკრეტული ამოცანისთვის.
- მაქვს იმედი, რომ მხოლოდ A-scan მონაცემის შემთხვევაშიც შეძლებს არსებული მოდელი დამარხული ობიექტის აღმოჩენას და განზოგადებას. რა თქმა უნდა არ ვგულისხმობ სიგნალების დამატებითი დამუშავების გარეშე ნებისმიერი ობიექტის ნებისმიერ სიდრმეზე აღმოჩენას. საწყისად, ამ კვლევის მიზნად დასახული მაქვს კონკრეტული ტიპის ობიექტის ფიქსირებულ სიდრმეზე აღმოჩენა რაც შეიძლება მაღალი სიზუსტით. პირველი ეტაპის წარმატების შემთხვევაში, შეიძლება ვიფიქროთ შემდეგ ნაბიჯებზეც.

ერთი შეხედვით, ეს ვარაუდები ზედმეტად ოპტიმისტურია, თუმცა ჩემს ყოველ ასეთ ვარაუდს აქვს საფუძველი და მანქანური სწავლების მუშაობის პრინციპში გარკვევისას გასაგები გახდება, თუ რატომ შეიძლება ჰქონდეს შემოთავაზებულ მეთოდს რაიმე უპირატესობა. თუმცა, აქვე უნდა ითქვას, რომ არსებული ვარაუდების დადასტურება ან უარყოფა მხოლოდ ამ კონკრეტული კვლევის შედეგებით არასწორი იქნება და საჭიროა მომავალში, კარგად გამართული ინვენტარით, დამატებითი მოკვლევა. თუმცა, ამ ეტაპზეც ვცდლობ სწორად, მხოლოდ ფაქტებზე დაყრდნობით ვიმსჯელო და ვტოვებ სივრცეს ჯანსაღი კრიტიკისთვის.

ამგვარი მსჯელობით ლოგიკურად მივდივით პროექტის ტექნიკური ამოცანის დასმამდე, რაც მდგომარეობდა შემდეგში:

- უნდა მომეძიებინა პროექტისთვის საჭირო ნივთები
- მომეწყო საექსპერიმენტო გარემო
- შემეგროვებინა დიდი რაოდენობის მონაცემები
- გამეწვრთნა ჩემი მოდელი ამ მონაცემებზე
- საბოლოოდ გამეტესტა მიღებული მოდელი

როგორც შემდგომში აღმოჩნდა, ამ მარტივი გეგმის განხორციელებას სჭირდებოდა საკმაოდ დიდი დრო და ენერგია, რაც მოხმარდა ინფორმაციის მოძიებას და სხვადასხვა ინჟინრული თუ პროგრამული პრობლემების გადაჭრას. სწორედ ამაზე ვაპირებ მომდევნო თავებში საუბარს, სადაც ვისაუბრებ საკუთარი გამოცდილებით და ყველა პრაქტიკულ მაგალითს განვიხილავ, რასაც კი პროექტის მსვლელობისას გადავაწყდი.

ტექნიკური მხარე


გამოყენებული მასალები და მათი აღწერა

მონაცემების შესაგროვებლად საჭიროა გვექონდეს ვექტორული ქსელის ანალიზატორი (VNA), რომლითაც მივიღებდით A-scan მონაცემს, დროზე დამოკიდებულ ფუნქციას. ერთ-ერთი პირველი პრობლემა რასაც გადავწყვედით იყო სწორედ ის, რომ ჩვენს VNA-ს არ შეეძლო Time Domain-ში სიგნალის მიღება, შეეძლო მხოლოდ სიხშირულ სპექტრში ქსელის სხვადასხვა პარამეტრების გაზომვა. ინტერნეტში მოკვლევის შემდეგ გავიგე, რომ იმპულსზე პასუხს, როგორც დროზე დამოკიდებულ ფუნქციას, გვაძლევდა S-პარამეტრების გაზომვა და მათი უკუფურიეს აღება. ამიტომაც, მონაცემების შეგროვება და შემდეგ დროით სიგნალად გადაყვანა შესაძლებელი იყო.



სურათი 9. ერთ-ერთი ვექტორული ქსელის ანალიზატორი

რაც შეეხება ანტენებს, გამოვიყენე ე.წ. ვივალდის ანტენა, რომელიც მიმართულებითი ანტენაა და სიგნალის დიდ ნაწილს გზავნის/იღებს მხოლოდ ერთი მიმართულებიდან. ეს ჩვენს შემთხვევაში კარგია იმისთვის, რომ ელექტრომაგნიტური ტალღები გავგზავნოთ ერთი, მხოლოდ ნიადაგის, მიმართულებით. არსებობს მიმართულებითი ანტენების სხვა სახეობებიც, მაგალითად Horn Antenna, Helical Antenna, Parabolic Antenna, მაგრამ პროექტისთვის სრულიად საკმარისი იყო Vivaldi Antenna რომლის Bandwidth არის 1.7გჰც-დან ექვს და მეტ გჰც-მდე. ვივალდის ანტენა, იმასთან ერთად, რომ მიმართულებითია, გააჩნია განიერი სიხშირეთა ზოლის სიგანე. თუ გვსურს დროითი სიგნალის მაღალ რეზოლუციაში მიღება, გამოჩნდება რომ საჭიროა რაც შეიძლება მეტი Bandwidth-ი. GPR შეიძლება გაკეთდეს როგორც ერთი, ისე ორი ანტენით. ამ პროექტში ორი ანტენის გამოყენება გადაწყვიტეთ (Bistatic) და ორივე მათგანს ჩამოსვლისთანავე 3D პრინტერზე დაუბეჭდეთ ფიქსატორი.



სურათი 10. გამოყენებული ვივალდის ანტენა


ნებისმიერ ანტენას, მიუხედავად მწარმოებლის მიერ გაკეთებული წარწერისა, რომ ერთ კონკრეტულ სიხშირეზე მუშაობს, რეალურად შეუძლია მრავალ სხვადასხვა სიხშირეზე მუშაობა, მაგრამ ყველაზე ოპტიმალურად სწორედ მწარმოებლის მიერ მითითებულზე მუშაობს. ვექტორულ ქსელის ანალიზატორს შეუძლია ანტენის ამ მახასიათებლების შეფასება. მაგალითად არსებობს ანტენის მახასიათებელი VSWR (Voltage Standing

Wave Ratio), რომელიც $(1, \infty)$ მნიშვნელობებს იღებს და სიხშირეზე დამოკიდებული. მარტივად რომ ვთქვათ, კონკრეტულ სიხშირეზე თუ VSWR არის 2-ზე ნაკლები, შეიძლება ჩავთვალოთ რომ ანტენა ამ სიხშირეზე კარგად მუშაობს. თუ VSWR არის 3, ამ სიხშირეზე ანტენა გადაცემული ენერგიის მხოლოდ 75%-ს ასხივებს, რაც უკვე ძალიან ცუდი შედეგია. არსებობს იგივე პარამეტრის სხვანაირი ჩაწერის ფორმატი, მაგალითად Return Loss (dB) და Reflection Coefficient (dB). არსებობს მათ შორის [კონვერტაციის ცხრილებიც](#), მაგრამ ჩემს შემთხვევაში მწარმოებლის მიერ VSWR იყო მოცემული.



სურათი 11. გამოყენებული კაბელი

ანტენა რომ VNA-ზე შემეერთებინა, დამჭირდა კაბელის გამოწერაც (ისეთი როგორიც ზედა სურათზეა), რომელიც ანტენის SMA კონექტორზე ერგებოდა. კოაქსიალური კაბელი აუცილებელია, რათა მასში გამავალ სიგნალზე გავლენა არ ჰქონდეს გარე ელექტრომაგნიტურ სიგნალს (და არც პირიქით). ის მაღალი სიხშირის სიგნალების უდანაკარგოდ გადასატანად გამოიყენება. SMA კონექტორიან კაბელს სანამ გამოვიწერდი, ვიყენებდი გადამყვანს, რომელიც N-type პორტიან კაბელს SMA კონექტორიან ანტენასთან აკავშირებდა. ეს ამკარად უარესობისკენ ცვლიდა ანტენის პარამეტრებს (VSWR), ამიტომ ჩავთვალე რომ ცდად ღირდა კაბელის გამოწერა და გადამყვანების გარეშე ამის ცდა, თუმცა ამან სამწუხაროდ არ იმუშავა და საქმეს თავიდანვე ეტყობოდა, რომ კალიბრაციის პრობლემამდე მივიდოდა. კალიბრაციაზე ცალკე ვისაუბრებ, მაგრამ იმის საილუსტრაციოდ თუ რას ვგულისხმობ, ქვედა სურათზე არის შედარება როგორი იყო VSWR პარამეტრი და როგორი უნდა ყოფილიყო ის.



სურათი 12. სასურველი პარამეტრი (მარცხენი) და არსებული (მარჯვნივ)

საექსპერიმენტო გარემოს მოწყობა

უნივერსიტეტში არსებული _Rohde & Schwarz_ ფირმის VNA-ით სანამ აზომვებს ავიღებდი, საჭირო იყო ექსპერიმენტისთვის საჭირო დანარჩენი მასალების მომარაგება. მასალად, რომელში ჩამარხული ობიექტის ამოცნობასაც ვაპირებდი, გამოვიყენე ყვითელი სამშენებლო ქვიშა, წონით 100კგ. ამ მასალის მიახლოებითი დიელექტრიკული შეღწევადობა [3-დან 6-მდე მერყეობს](#). ავარჩიე რამდენიმე დასამარხი ნივთი, რომლებიც განსხვავდებოდნენ როგორც დიელექტრიკული და მაგნიტური შეღწევადობის მნიშვნელობებით, ასევე ფორმით. რადგან სასურველი მიზანია ერთმანეთის მსგავსი ობიექტების ამოცნობა, თითოეული ამ ნივთისთვის მჭირდებოდა რამდენიმე მათი მსგავსი ნივთი. ყველაზე მარტივად რისი მოძიებაც შევძელი, არის ე.წ. LiPo აკუმლატორები, რომლებიც უნივერსიტეტის ლაბორატორიაში ვიპოვე. ერთი ასეთი აკუმლატორი დაახლოებით აგურის ზომისაა, რაც გატესტვას შედარებით მარტივს ხდის. ამის მომდევნო ნაბიჯი იყო ხელსაწყოს გამართვა, რათა პირველი წარმატებული გაზომვა გამეკეთებინა, შემდეგ კი ბევრი მონაცემი ერთდროულად მომეგროვებინა და ამაზე დაყრდნობით შემეძმნა მოდელი, რომელიც შეძლებდა სწორად პროგნოზირებას, იყო თუ არა მიწის ქვეშ დამარხული LiPo აკუმლატორი. თუ ამ ტიპის ნივთზე მოდელი წარმატებულად იმუშავებდა, მაშინ სავარაუდო იყო რომ ის განზოგადდებოდა სხვა ერთმანეთის მსგავს ობიექტებზეც.



სურათი 13. დასამარხად გამოყენებული LiPo აკუმლატორები

VNA-ს კალიბრაცია

ვექტორული ქსელის ანალიზატორს, როგორც წესი, მაღალ სიხშირეებთან სამუშაოდ იყენებენ. VNA-სთან წარმატებული მუშაობის ერთ-ერთი მთავარი წინაპირობაა მისი კალიბრაცია. რადგან მაღალ სიხშირეებთან გვაქვს საქმე, ნებისმიერი მოწყობილობა, რომელიც DUT-სა და VNA-ს შორის ჯდება, ცვლის/ამახინჯებს S-პარამეტრებს. საბედნიეროდ, ამგვარად შეცვლილ S-პარამეტრებს იწვევენ სისტემური შეცდომები, რომელიც, არასისტემური შეცდომისგან განსხვავებით, თითქმის სრულიად გამოსწორებადია კალიბრაციის მეშვეობით.

კალიბრაციის პროცედურისთვის საჭიროა შესაფერისი მოწყობილობა, რომლის მახასიათებლები ძალიან დიდი სიზუსტით წინასწარაა ცნობილი VNA-სთვის. როცა VNA-ზე ამ მოწყობილობას შევაერთებთ DUT-ად, VNA-მ ზუსტად იცის თუ როგორი პასუხი ექნება გამოსასვლელზე ამ მოწყობილობისთვის. ამიტომ, ისეთი სისტემური შეცდომები, რომელიც წინასწარ ცნობილი VNA-ს პასუხისგან აცდენას იწვევენ, ავტომატურად ბათილდება VNA-ს მიერ. კალიბრაციისთვის არსებობს სხვადასხვა მოწყობილობები, რომლებიც ან სრულიად ავტომატურია, ან საჭიროებს ხელით პორტების მორგებას, რათა საბოლოოდ VNA დავაკალიბროთ. ნებისმიერ შემთხვევაში, კალიბრაციისთვის საჭირო მოწყობილობას აგრეთვე მოყვება ფაილი, რომელიც ამ კონკრეტული მოწყობილობის მახასიათებლებს შეიცავს. სხვა სიტყვებით, ყველა კალიბრაციის ხელსაწყო ერთმანეთის თანასწორი არაა და საჭიროა მისი მახასიათებლების ცოდნა.



სურათი 14. კალიბრაციის კრებული

თუ კალიბრაციის კიტი გვაქვს, კალიბრაციის მრავალი მეთოდი შეიძლება გამოვიყენოთ, რომელიც დამოკიდებულია თუ რომელი პარამეტრების გაზომვა გვსურს და რამდენპორტიანია VNA. რადგან ლაბორატორიის ანტენა ორპორტიანია, ავირჩიე TOSM კალიბრაცია, რომლის შემდეგაც შევძლებთ ყველა S-პარამეტრის გაზომვას. უნივერსიტეტში ამისათვის არის შესაბამისი კალიბრაციის კრებული, თუმცა ეს კრებული არის მხოლოდ N-type შესაერთებლიანი კაბელებისთვის, ჩვენს ვივალდის ანტენებს კი SMA კონექტორები ჰქონდა, რომელიც დიამეტრით ბევრად პატარაა.

ამ პრობლემის გამო განვიხილავდი 3.5mm კონექტორებიანი კალიბრაციის კრებულის ყიდვას, რომელიც SMA-ზე ერგება, მაგრამ ძვირი ჯდება. ამიტომ მომიწია სხვა გამოსავალზე დაფიქრება და გამახსენდა, რომ დაკალიბრებულ N-type კაბელს როცა პირდაპირ ვაღებდი ანტენის SMA პორტზე, ანტენის მახასიათებლები ზუსტად ემთხვეოდა მწარმოებლის მიერ მოცემულს. თუ ეს შესაძლებელი იყო, მაშინ შესაძლებელი უნდა ყოფილიყო პირიქით, SMA კაბელის პირდაპირ მიღება კალიბრაციის კრებულის N-type პორტზე. როცა ეს მეთოდი ვცადე, სამწუხაროდ კონექტორები ერთმანეთს არ მოერგო და თუ კალიბრაცია მჭირდებოდა, მაშინ საჭირო იყო როგორმე შესაბამისი კალიბრაციის კიტის შოვნა, რაც იმ ეტაპისთვის არ განიხილებოდა. ამიტომ, განვაგრძე მუშაობა კალიბრაციის გარეშე იმ იმედით, რომ ჩემი სტრატეგია კალიბრაციის საჭიროებას გამორიცხავდა.

მონაცემების შეგროვება

ცნობილია, რომ მანქანური სწავლების ერთ-ერთი მთავარი კომპონენტია მონაცემების შეგროვება. მონაცემები უნდა იყოს დიდი რაოდენობით, მაგრამ ხარისხიანი. თუ მონაცემები მწირია ან არაა საკმარისად მრავალფეროვანი (განსხვავდება რეალური სატესტო მონაცემებისგან), მაშინ ჩვენი მოდელი განწირული იქნება კრახისთვის. არსებობს რამდენიმე ფაქტორი, რაც განსაზღვრავს თუ რამდენი მონაცემია საჭირო ჩვენი მოდელისთვის. ეს დამოკიდებულია, მაგალითად, პარამეტრების რაოდენობაზე, სიგნალის და ხმაურის თანაფარდობაზე, კორელაციის ხარისხსა და იმ სფეროზე, რომელშიც ჩვენი პრობლემა დავსვით. ამ კონკრეტულ შემთხვევაში ამაზე არანაირი კვლევა არ ჩატარებულა, ამიტომ გაუგებარი იყო რა რაოდენობის მონაცემი დამჭირდებოდა. თუმცა, ის ცხადი იყო, რომ საჭირო იყო მონაცემების შეგროვების ავტომატიზაცია. როცა მაქვს 1000 სხვადასხვა პარამეტრი (VNA გაზომვას 1000 თანაბრად დამოკიდებული სიხშირისთვის აკეთებდა), ალბათ საჭიროა მინიმუმ 10-ჯერ მეტი მონაცემის შეგროვება, რათა გამოიკვეთოს ორ კლასს შორის განსხვავება. ხელით გაზომვის გაკეთება და მისი ფაილში დამახსოვრება კი ამდენი მონაცემის შეგროვებისთვის არარეალურად დიდ დროს მოითხოვდა.

data-miner-v1

თუ 100 მონაცემი ხელით 5 წუთში გროვდება, 10000 მონაცემს დაჭირდებოდა 3 დღე-ღამეზე მეტი. როცა რამდენიმე წარუმატებელი მცდელობის შემდეგ დავწერე პროგრამა, რომელიც VNA-დან ავტომატურად იღებდა გაზომვებს და იმახსოვრებდა, ამდენივე მონაცემის შესაგროვებლად მას დაახლ. 12 საათი სჭირდებოდა. პროგრამა დაწერილია Python ენაზე და ძირითადად გამოყენებული მაქვს PyAutoGUI ბიბლიოთეკა, რომელიც მაუსის კლიკების ავტომატიზაციის საშუალებას იძლევა. პროგრამის მუშაობის პრინციპი ძალიან მარტივია. ის, რაც ხელით უნდა მეკეთებინა VNA-ს სენსორებზე, კეთდება მაუსის პროგრამულად მოძრაობით. პროგრამას აქვს კონფიგურაციის ფაილი, სადაც მაგალითისთვის შეიძლება თითოეული ქვეოპერაციის დროის მითითება, რაც Debugging-ს მარტივს ხდის. კონფიგურაციის ფაილშივე უნდა მიეთითოს იმ დილაკების კოორდინატები, სადაც მაუსის კლიკი უნდა მოხდეს. მომხმარებელს აქვს შესაძლებლობა დააპაუზოს ან ნაადრევად გააჩეროს პროგრამა. პროგრამა VNA-ს აკეთებინებს გაზომვას და წინასწარ განსაზღვრულ ფოლდერში იმახსოვრებს მას, დასახელების ზრდადობით.

data-miner-v2

როცა პროგრამის პირველი ვერსიის მუშაობის სისწრაფე არ იყო მისაღები, რადგან გაირკვა რომ ექსპერიმენტის მსვლელობის დროს მჭირდებოდა ადგილზე ყოფნა. დავიწყე ფიქრი არსებული დროის გაუმჯობესებაზე. თეორიულად, VNA ერთ გაზომვას მხოლოდ რამდენიმე მილიწამს ანდომებს და შესაძლებელი უნდა იყოს ძალიან ბევრი მონაცემის უმოკლეს დროში შეგროვება, თუმცა იმის გამო, რომ მოწყობილობაზე Windows 7 აყენია და პროგრამასთან პირდაპირი ინტერაქცია არ შემოიღია, მონაცემების სწრაფად შეგროვება რთულია, რადგან მიწევს GUI-სთან ინტერაქცია. როცა პროგრამის გაუმჯობესება გადაწყვიტე, რამდენიმე საათში მზად მქონდა მეორე ვერსია, რომელიც სარგებლობდა VNA-ის იმ ფუნქციით, რომელიც ჯერ რამდენიმე გაზომვას ერთად იღებდა და შემდეგ იძლეოდა ყველას ფაილში დამახსოვრების შესაძლებლობას. ამან მნიშვნელოვნად შეამცირა მაუსის მოძრაობისთვის საჭირო მანძილი, შესაბამისად დროც. 1000 მონაცემი გროვდებოდა 20 წუთში. წინა ვერსიასთან შედარებით ეს 4-ჯერ სწრაფი აღმოჩნდა.

servo-controller


გადაწყვიტე, რომ VNA-ს ბრძენებების ავტომატიზაციასთან ერთად ანტენაც ჩემი დახმარების გარეშე ყოფილიყო ფიქსირებული. ანტენის სტატიკურად დადების შემთხვევაში შეგროვილი მონაცემები ერთმანეთს ძალიან ემგვანებოდა, რაც სირთულეს შეუქმნიდა ჩემს მოდელს რეალურ მონაცემებზე განზოგადებაში. შესაბამისად, მივიღე გადაწყვეტილება რომ ანტენის ერთი ბოლო ძაფით დამეფიქსირებინა ქვიშის ზედაპირიდან მუდმივ სიმაღლეზე, ხოლო მეორე ბოლო მემოძრაებინა სერვოს მეშვეობით, რომლის კონტროლერადაც არდუინოს ბორდი ავარჩიე. ასეთი კონფიგურაცია ანტენას ამყოფებდა დაახლოებით ერთ სიმაღლეზე, მაგრამ დროთა განმავლობაში შეუცვლიდა კუთხეს, რაც შეგროვილ მონაცემებს უფრო მრავალფეროვანს გახდიდა.

ამ მინი-პროექტისთვის ბევრი წვრილმანი დეტალის გათვლა დამჭირდა, რაშიც შედიოდა კვების წყაროს მოძიება და კაბელების გაყვანა, არდუინოს კოდის დაწერა რომელსაც ლეპტოპიდან გავუგზავნიდი ბრძანებებს და სიჩქარეს ან კუთხის დიაპაზონს მივუთითებდი. დამჭირდა რგოლის გაკეთებაც ორგანული მინისგან, რაც სერვოზე მაგრდებოდა და შემდეგ მასზე ეხვეოდა ძაფი. ამ პატარა პროექტის შექმნაზეც კი ბევრი ადამიანის დახმარება და დრო დამჭირდა. საბოლოოდ შედეგი ისეთი გამოვიდა, როგორც გავთვალე. data-miner პროგრამასთან ერთად შემეძლო servo-controller ავტომატურ რეჟიმზე დამეტოვა და სახლში წავსულიყავი. მეორე დღეს 60000-მდე ახალი მონაცემი მხვდებოდა.

მონაცემების დამუშავება და მოდელის შექმნა

არაერთხელ ვახსენე, რომ კარგი მონაცემების შეგროვება ძალიან რთულია. ჩემს მიერ აწყობილი სისტემა, რომელიც მონაცემებს ავტომატურად აგროვებდა, ისე მუშაობდა როგორც გათვლილი იყო, თუმცა მონაცემებს მაინც აკლდათ ვარიაცია რამდენიმე მნიშვნელოვანი მიზეზის გამო. რეალურად, ამ მიზეზებს დროთა განმავლობაში ვაიდენტიფიცირებდი, რადგან პარალელურად ვმუშაობდი ამ მონაცემების დამუშავებასა და მანქანური სწავლების მოდელის შექმნაზე. ჩემი მონაცემების შეგროვებისადმი მიდგომა დროთა განმავლობაში იცვლებოდა, ამიტომ პროექტზე მუშაობის ქრონოლოგიური ხაზის დარღვევის გარეშე არ შემოიძლია ყველა ეს მიზეზი ჩამოვთვალო, თუმცა ეს ღირს, რადგან უფრო ლოგიკურია მონაცემებთან დაკავშირებული ყველა ინფორმაციისთვის თავის ერთად მოყრა.

უნდა აღინიშნოს, რომ ჩემი ერთი მონაცემი არის სიხშირეზე დამოკიდებული ფუნქცია, რომელიც განსაზღვრულია (1.7გჰც, 8.5გჰც) შუალედში. ეს ფუნქცია რეალურად არის S21 პარამეტრი, რაც უხეშად რომ ვთქვათ, ზომავს პირველი ანტენიდან გაგზავნილი სიგნალის რა წილი მიიღო მეორე ანტენამ. თუ ანტენები მიმართული იქნება ზედაპირისკენ, რომელიც სრულიად შთანთქავს ელექტრომაგნიტურ ტალღებს, ეს პარამეტრი იქნება ძალიან მცირე. თუ ზედაპირმა ელექტრომაგნიტური ტალღა სრულად აირეკლა, მაშინ ეს ფუნქცია მიიღებს შედარებით მაღალ მნიშვნელობებს. ცხადია, ეს პარამეტრი განსხვავებული იქნება მაშინ, როცა მხოლოდ ქვიშისკენაა მიმართული ვიდრე მაშინ, როცა ქვიშაში რაღაც არის დამარხული. დამარხული ობიექტი ზოგ სიხშირეს შთანთქავს, ზოგს აირეკლავს, ზოგსაც კი გარდატეხს. ეს კომპლექსური პროცესი საკმარის განსხვავებებს გამოიწვევს ორი ტიპის სიგნალს შორის, და ზუსტად ამ სხვაობის დასწავლა მოუწევს ხელოვნურ ინტელექტს.



სურათი 15. ტიპური S21 პარამეტრი


გაზომილ S21 პარამეტრის ბევრი ფორმატით ჩაწერა შეიძლება. მე ავირჩიე ე.წ. Linear Magnitude, რომელიც (0, 1) მნიშვნელობებს იღებს. აგრეთვე, ის თანაბრად დაშორებულ 1000 წერტილშია განმარტებული. აქამდე ვახსენე, რომ A-scan დროზე დამოკიდებული ფუნქციაა, თუმცა საბოლოოდ გადაწყვიტე, რომ დროზე დამოკიდებული ფუნქციის მაგივრად პირდაპირ სიხშირული სპექტრი გადამეცა, რაც შერჩეული მოდელის წრფივობასთანაა კავშირში.

ეს მაშინ გადავწყვიტე, როცა ვცდილობდი ჩემს მიერ მიღებული მონაცემი დროით სიგნალად გადამეყვანა. რა თქმა უნდა ეს არ გამომივიდა, რადგან Linear Magnitude არის დროითი სიგნალის ფურიე გარდაქმნის მოდული. სხვა სიტყვებით, ჩემს მონაცემს თან არ ახლდა ფაზური ინფორმაცია. ეს A-scan სიგნალის მიღებისთვის პრობლემას წარმოადგენდა, რადგან უკუფურიესთვის გვჭირდება ფაზური ინფორმაცია, თუმცა მოდულის გაწვრთნისთვის ვფიქრობ მნიშვნელობა არ ჰქონდა, რადგან დროითი სიგნალი ანტენის ზემოთ-ქვემოთ მოძრაობით წანაცვლდება, ხოლო სიხშირული სპექტრისთვის ეს მხოლოდ ფაზურ ნაწილს ცვლის. არ იქნება კარგი, ჩვენი მოდელი რომ ძალიან დამოკიდებული იყოს ანტენის ზედაპირიდან დაშორებაზე. მთავარია ინფორმაცია, რომელიც დროით სიგნალში სიხშირეთა განაწილების პროპორციულობაზე მეტყველებს, რაც ფურიე გარდაქმნის მოდულია. დროში სიგნალის წანაცვლებით ფურიე გარდაქმნის მოდული არ იცვლება.


$$\begin{aligned}\mathcal{F}\{g(t-a)\} &= \int_{-\infty}^{\infty} g(t-a)e^{-i2\pi ft} dt \\ &= \int_{-\infty}^{\infty} g(u)e^{-i2\pi f(u+a)} du \\ &= e^{-i2\pi fa} \int_{-\infty}^{\infty} g(u)e^{-i2\pi fu} du \\ &= e^{-i2\pi fa} G(f)\end{aligned}$$

სურათი 16. დროში წანაცვლებული სიგნალის ფურიე გარდაქმნა

მონაცემების შეგროვებასთან ერთად წარმოიშვა კიდევ ერთი პრობლემა, რომელიც ე.წ. overfit-ს უკავშირდება. თავდაპირველად მონაცემებს სრულიად ავტომატურ რეჟიმში ვაგროვებდი. ჯერ ვათანაბრებდი ქვიშის ზედაპირს, ვაკონფიგურებდი VNA-სა და სერვოს, შემდეგ კი მთელი ღამის განმავლობაში ვტოვებდი. თავიდანვე ვფიქრობდი, რომ ასეთი მონაცემებით გაწვრთნილ მოდელს ექნებოდა ოვერფიტის პრობლემა. ვეცდები ცნობილი მაგალითების დახმარებით ავხსნა თუ რას ნიშნავს ეს. ჩავთვალოთ რომ გვაქვს მხოლოდ ერთ ცვლადზე დამოკიდებული მონაცემები, რომლებითაც სტატისტიკური მეთოდით ვაპირებთ პოლინომიალის "მორგებას". თუ შევარჩევთ ზედმეტად დაბალი ხარისხის პოლინომიალს, მონაცემებს ის ზუსტად ვერ მოერგება და იქნება დიდი ცდომილება, რასაც ანდერფიტი ეწოდება. ხოლო თუ ძალიან მაღალი ხარისხის პოლინომიალი გვექნება, მაშინ ის მონაცემებში არსებულ ხმაურსაც ისწავლის და დამატებითი მონაცემების შემოსვლისას ცდომილებას მოგვცემს. ორივე ასეთი შემთხვევის საჩვენებელი გრაფიკი შემდეგ გვერდზეა მოცემული.



სურათი 17. underfit-ის მაგალითი



სურათი 18. overfit-ის მაგალითი

ოვერფიტის ერთ-ერთი [ცნობილი ისტორია](#), რომ აშშ-ს არმია ცდილობდა შეექმნა მოდელი, რომელიც სურათებიდან შეძლებდა რთულ რელიეფზე ტანკების ამოცნობას. მოგვიანებით აღმოჩნდა რომ მოდელი რეალურ მონაცემებზე არ მუშაობდა, რადგან იმის მაგივრად, რომ გაერჩია რომელ სურათზე იყო ტანკი და რომელზე არა, ისწავლა ღრუბლიანი ცის მოწმენდილისგან გარჩევა. როცა მოგვიანებით შეამოწმეს, სურათები, რომლებზეც ტანკები იყო, გადაღებული იყო ღრუბლიან ამინდში, ხოლო ისინი რომელზეც ტანკები არ იყო, მზიან ამინდში. ესეც ხმაურის დასწავლის ერთ-ერთი მაგალითია.

ჩემს მონაცემებსაც ოვერფიტის პრობლემა ჰქონდა, მაგრამ ფრთხილად ვიყავი და ასეთ შედეგს ველოდი, ამიტომ ამაში ბევრი დრო არ დამიკარგავს. როცა ჩარევის გარეშე ვატარებდი ექსპერიმენტს, ქვიშის ზედაპირი იგივე იყო, ამიტომ მოსალოდნელი იყო რომ მოდელი ამ კონრეტულ ქვიშის ზედაპირს დაისწავლიდა, რადგან ქვიშის ზედაპირიდან არეკლილი ტალღის წილი ბევრად დიდია, ვიდრე სამიზნე ობიექტიდან. შესაბამისად, ქვიშის ზედაპირიც ერთგვარი ხმაური იყო ჩემს შემთხვევაში. ეს რომ შემემოწმებინა, მოდელი დავატრენინგე ქვიშის ზედაპირის შეცვლის გარეშე, მაგრამ სატესტო მონაცემებისთვის ქვიშის ზედაპირს ხელით ვცვლიდი და ისე ვიღებდი გაზომვას. შედეგი ის იყო, რომ მოდელი დასატრენინგებულ მონაცემებს დიდი სიზუსტით არჩევდა ერთმანეთისგან, მაგრამ სატესტო მონაცემებზე სიზუსტე მხოლოდ 70% იყო. ეს ნიშნავდა იმას, რომ თუ მინდოდა კარგი მონაცემები შემეგროვებინა, მუდმივად უნდა მეცვალა ქვიშის ზედაპირი რაღაც დროში ერთხელ და ისე ამელო მონაცემები.

ამგვარი მონაცემების შეგროვების შემდეგ სიზუსტე საგრძნობლად აიწია, ამიტომ უკვე დავიწყე სხვა LiPo ბატარიების გამოყენება. რამდენიმე მათგანი ერთი და იგივე დღეს დავმარხე და აღმოვაჩინე, რომ მოდელს ძალიან უჭირდა დამარხული ნივთების აღმოჩენა. საერთოდ ყველაფერზე ეგონა რომ ქვიშა იყო, თანაც მაღალი სარწმუნოებით. ამ დროს უკვე ბევრი სხვადასხვა მონაცემი მქონდა შეგროვილი სხვადასხვა დროს, ამიტომ დავიწყე მათი რეორგანიზება. ვიფიქრე, რომ ოვერფიტი შეიძლებოდა LiPo ბატარიის ორიენტაციაზე ყოფილიყო დამოკიდებული. მართლაც, რომ შევამოწმე, მოდელს მხოლოდ ერთ-ერთ ორიენტაციაში (წარწერით ზემოთ) შეეძლო დამარხული ობიექტის აღმოჩენა. ამის გამო ავიღე უამრავი მონაცემი, სადაც ბატარია წარწერით ქვემოთ დავდე და ისე ავიღე მონაცემები.

ასეთმა მოდელმა იმუშავა, თუმცა შემდეგ აღმოვაჩინე რომ ისეთ ახალ მონაცემს ვეღარ ცნობდა, რომელშიც ცარიელი ქვიშა იყო. ეს საინტერესოა, რადგან ქვიშის ამოცნობა ყოველთვის შეეძლო. საბოლოოდ ვიფიქრე, რომ ეს მონაცემების სხვადასხვა დროს აღების ბრალია. თავიდან როცა ქვიშა მოვიტანეთ, ფხვიერი და მშრალი იყო. დროთა განმავლობაში ის დატენიანდა და დაკრისტალდა, საკმაოდ დიდი და მყარი კენჭები გაჩნდა მასში. საუკეთესო შემთხვევაში, ასეთი შემთხვევები მომავალში უნდა გამოირიცხოს, თუმცა ამჯერად ექსპერიმენტის ახლიდან გამეორებისთვის დრო აღარ მქონდა და რამდენიმე ათასი ახალი მონაცემი შევაგროვე, აღებული მხოლოდ ქვიშიდან. სწორედ ასეთ მონაცემებზეა დატრენინგებული მოდელი ამჟამად და საკმაოდ დიდი (80% და მეტი) სიზუსტით მუშაობს.



სურათი 19. პროექტის სრული კონფიგურაცია

მიღებული შედეგი და დასკვნა

პროექტის საბოლოო შედეგი ისაა, რომ შესაძლებელია ქვიშაში დავმარხოთ ობიექტი, ავიღოთ GPR-ით მონაცემი, გადავცეთ ჩვენს მიერ პროგრამულად შექმნილ სტატისტიკურ მოდელს და 80% ან მეტი სიზუსტით მივიღოთ სწორი შედეგი. თუ გვსურს კონკრეტული რამ, მაგალითად ცრუ უარყოფითი შედეგების მინიმიზაცია, ამის მოხერხება შესაძლებელი იქნება ცრუ დადებითების გაზრდის ხარჯზე.

პროექტს აქვს განვითარების დიდი პერსპექტივა, რადგან შესაძლებელია სიგნალის გაფილტვრით და უკეთესი საექსპერიმენტო გარემოს მოწყობით, უკეთესი მონაცემები მივიღოთ და მასზე სტატისტიკური მოდელის მორგება ბევრად გამარტივდება. როგორც ვნახეთ, მოდელს უფრო ხშირი პრობლემა ექმნება ოვერფიტის და არა ანდერფიტის. ნაპოვნი მაქვს ლოგისტიკური რეგრესიისთვის ოპტიმალური პარამეტრებიც, რომელიც დიდ კომპიუტერულ რესურსს მოითხოვს და რამდენიმე დღიანი ლოდინი დამჭირდა.

აგრეთვე, შეგვიძლია სტატისტიკური მოდელის კოეფიციენტების ერთგვარი ინტერპრეტირება, რაშიც ვგულისხმობ იმას, რომ თუ რომელიმე სიხშირის შესაბამისი კოეფიციენტი დადებითია, მაშინ ამის ინტერპრეტაცია იქნებოდა ის, რომ რაც მეტია ამ კონკრეტულ სიხშირეზე S-პარამეტრი, მით უფრო დიდია შანსი რომ მიწაში დამარხული ობიექტი ვიპოვოთ.

პროექტი მზა ფორმაში მაქვს ატვირთული GitHub-ზე და ყოველთვის ვამატებ ახალ-ახალ კოდს. მონაცემების ზომა დიდია და ჯერ-ჯერობით პირადად მაქვს შენახული. უმუშალოდ ტრენინგის პროცესი ერთ-ერთ ნოუთბუქშია დეტალურად აღწერილი, ამიტომ აქ აღარ დავწერე. პროექტის ანგარიშში არც დეტალურ პროგრამულ იმპლემენტაციას ვწერ, რადგან სრული კოდი ონლაინში მაქვს, სხვა ბევრ დამხმარე ფაილთან თუ სკრიპტთან ერთად. გამოყენებული ლიტერატურა თანდართულია readme.md ფაილთან.

პროექტის მისამართი: <https://github.com/lnadi17/ground-penetrating-radar>